

# Motivation I: Der Datensatz täuscht

- Qualitätsindikatoren unterscheiden sich signifikant zwischen den Datensatzteilen
- Ursache: Klassenlabel ist mit der Videoquelle konfundiert (uniform vs. heterogen)
- Mögliches Risiko: Modelle können die Klasse an Oberflächenstatistik erkennen, ohne die Szene zu verstehen

# Motivation II: ZSL unplausibel gut

- Zero-Shot Qwen 3.5 (klein): 91 % Genauigkeit (Unfall), 100 % (Nicht-Unfall)
- Erklärungen
  - (a) Kollision ist in den Frames sichtbar → Detektion trivial; CCD war für *Antizipation* gedacht
  - (b) Oberflächenmerkmale statt Semantik
  - (c) mögliche Trainingsdaten-Kontamination (CCD seit 2020 öffentlich, Videos von YouTube) (Prompt an qwen, was es über ccd/bdd100k/youtube dashcam videos weiß)

# Motivation III: Antizipation ist schwerer als Detektion

- Nur Frames *vor* dem Unfall → Vorhersage „Wird ein Unfall passieren?“
- Ergebnis: Leistung sinkt deutlich, heißt Antizipation ist schwerer als Detektion
- Antizipation entspricht der eigentlichen Aufgabe: Kritikalitätsbewertung

# Motivation IV: Falsche Gründe

- Korrekte Klassifikationen mit falscher Begründung beobachtet
  - Beispiel: Artefakt auf Motorhaube als „UFO, das den Fahrer ablenkt“ interpretiert
- Richtige Klassifikation !→ richtiger Grund
- Konsequenz: Genauigkeit allein ist kein valider Nachweis von Szenenverständnis
- Die *Erklärungen* des Modells müssen selbst evaluiert werden

# Konsequenz: LoRA-Distillation jetzt nicht vertretbar

- Ursprünglicher Plan: LoRA-Fine-Tuning eines kleinen Modells auf Beschreibungen eines großen Lehrer-VLMs
  - Problem 1: Lehrer-Beschreibungen nicht skalierbar validierbar (manuelle Prüfung unrealistisch)
  - Problem 2: Einzelbeschreibung („one shot“) trägt kein Zuverlässigkeitsargument
  - Problem 3: Motivation I lässt Shortcut-Lernen beim Fine-Tuning auf CCD erwarten
  - Problem 4: Kein Maß, um Verbesserung der Beschreibungsqualität nachzuweisen
- Erst muss eine skalierbare Validitätsprüfung existieren

# Mögliche Forschungsfragen

- **RQ1:** In welchem Maße beruhen Zero-Shot-Kritikalitätsurteile auf Oberflächenmerkmalen (Qualität, Quellenartefakte) statt auf semantischem Inhalt?
  - Prompt vorschläge: Wie wahrscheinlich schätzt du es ein, dass ein YouTube-Video eines Kanals, der dashcam videos hochlädt, einen crash/eine kritische Situation enthält
  - Bei gegebenem Video: Was denkst du aus welcher Quelle dieses Video stammt? [Eher automotiv datensatz oder eher ein youtube dashcam kanal]
  - Zusätzlich: Methoden die konkrete Trainingsdaten „herausarbeiten“
- **RQ2:** Wie lässt sich die „Faithfulness“ der Modell-Erklärungen automatisch und skalierbar messen?
  - Zusatz zu RQ2: Wie hängt Erklärungstreue mit Klassifikationskorrektheit zusammen?
- **Subquestion RQ3:** Wie verändern sich Leistung und Grounding über Domänen und Aufgaben hinweg? Beispiele:
  - synthetisch (CARLA) ↔ real
  - Ego-Perspektive (Dashcam) ↔ statische Kamera (CCTV)
  - Detektion ↔ Antizipation